

UNIVERSIDADE FEDERAL DE SANTA MARIA  
CENTRO DE TECNOLOGIA  
CURSO DE GRADUAÇÃO EM SISTEMAS DE INFORMAÇÃO

Marinara Rübenich Fumagalli

**APLICAÇÃO DE REDES NEURAIIS ARTIFICIAIS PARA PREDIÇÃO  
DE PALEOTEMPERATURAS COM BASE EM AMOSTRAS DE  
FORAMINÍFEROS**

Santa Maria, RS  
2019

**Marinara Rübenich Fumagalli**

**APLICAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA PREDIÇÃO DE  
PALEOTEMPERATURAS COM BASE EM AMOSTRAS DE FORAMINÍFEROS**

Monografia apresentada ao Curso de Graduação em Sistemas de Informação da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Bacharela em Sistemas de Informação** .

**ORIENTADOR:** Prof. Joaquim Vinicius Carvvalho Assunção

Santa Maria, RS  
2019

**Marinara Rübenich Fumagalli**

**APLICAÇÃO DE REDES NEURAIS ARTIFICIAIS PARA PREDIÇÃO DE  
PALEOTEMPERATURAS COM BASE EM AMOSTRAS DE FORAMINÍFEROS**

Monografia apresentada ao Curso de Graduação em Sistemas de Informação da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Bacharela em Sistemas de Informação**.

**Aprovado em XX de julho de 2019:**

---

**Joaquim Vinicius Carvalli Assunção, Dr. (UFSM)**  
(Presidente/Orientador)

---

**Giliane Bernardi, Dra. (UFSM)**

---

**Luís Álvaro de Lima Silva, Dr. (UFSM)**

Santa Maria, RS  
2019

## **RESUMO**

# **APLICAÇÃO DE REDES NEURAIIS ARTIFICIAIS PARA PREDIÇÃO DE PALEOTEMPERATURAS COM BASE EM AMOSTRAS DE FORAMINÍFEROS**

**AUTORA:** Marinara Rübenich Fumagalli

**ORIENTADOR:** Joaquim Vinicius Carvalli Assunção

Foraminíferos são protistas unicelulares marinhos que existem desde o período Cambriano (entre 542 milhões e 488 milhões de anos atrás). Possuem duas formas: bentônicas e planctônicas. As bentônicas podem ter hábito infaunal: que vivem abaixo ou dentro dos sedimentos; ou epi-faunal: vivem na superfície dos sedimentos. As planctônicas vivem dispersas no oceano e podem movimentar-se verticalmente. São conhecidas milhares de espécies que se apresentam como microfósseis conservados nos estratos ou vivos até os dias atuais. São altamente evolutivos e sensíveis às mudanças ambientais. Sua carapaça, composta de carbonato de cálcio, é resistente e capaz de armazenar, dentre outras informações, variações paleoclimáticas. Através da análise de sua carapaça conseguimos analisar a proporção de isótopos de oxigênio acumulados nas carapaças e assim prever quais eram as temperaturas em determinados períodos geológicos. Para este trabalho, as previsões serão dadas por meio da aplicação de redes neurais artificiais com base em arquivos que contam com amostras da presença de espécies de foraminíferos. Redes Neurais Artificiais (RNAs) são baseadas nas comunicações e conexões entre os neurônios do cérebro humano, que nos possibilitam armazenar informações e aprendizagem. RNAs são capazes de aprender qual a melhor saída através de configurações referentes as entradas. São aplicados diferentes pesos entre as conexões, estes são calculados e podem ser ativados (1) ou não (0), a rede deve se adaptar a quaisquer entradas. Os treinamentos e testes da rede foram realizados através do RStudio e aplicadas na ferramenta Shiny, que possibilita a criação de aplicações Web. Na aplicação, o usuário seleciona o arquivo e tem como resultado a estimativa da temperatura da época em que as amostras viveram. Além de gráficos e cálculos estatísticos que informam a precisão do valor estimado.

**Palavras-chave:** Aprendizagem de Máquina. Foraminíferos. Inteligência Artificial. Paleoclima. Redes Neurais.

## **ABSTRACT**

# **APPLICATION OF ARTIFICIAL NEURAL NETWORKS FOR PALEOTEMPERATURES PREDICTION BASED ON FORAMINIFERA SAMPLES**

**AUTHOR:** Marinara Rübenich Fumagalli

**ADVISOR:** Joaquim Vinicius Carvalho Assunção

Foraminifera are marine unicellular protists that exists since the Cambrian period (between 542 million and 488 million years ago). They have two forms: benthic and planktonic. Benthic may have infaunal habit: living below or within sediments; or epifaunal: they live on the surface of sediments. The plankton live scattered in the ocean and can move vertically. Thousands of species are known to present themselves as microfossils preserved in the strata or living until present days. They are highly evolutionary and sensitive to environmental changes. Its carapace, composed of calcium carbonate, is resistant and capable of storing, among other information, paleoclimatic variations. Through of the analysis of its shell we were able to analyze the proportion of oxygen isotopes accumulated in the carapaces and thus to predict which were the temperatures in certain geological periods. For this work, the predictions will be given through the application of neural networks based on archives that have samples of the presence of foraminifera species. Artificial Neural Networks (ANNs) are based on the communications and connections between the neurons of the human brain, which enable us to store information and learning. ANNs are able to learn the best output through configurations pertaining to inputs. Different weights are applied between the connections, weights are calculated and can be activated (1) or not (0), therefore, the network must adapt to any inputs. The training and testing of the network were carried out through RStudio and applied to the Shiny tool, which allows the creation of Web applications. In the application, the user selects the file and has the result of estimating the temperature of the time the samples lived. In addition to graphs and statistical calculations that inform the accuracy of the estimated value.

**Keywords:** Machine Learning. Foraminifera. Artificial Intelligence. Paleoclimate. Neural Networks.

## LISTA DE FIGURAS

Figura 2.1 – Exemplos de foraminíferos planctônicos. ....	13
Figura 2.2 – Exemplos de foraminíferos bentônicos. ....	13
Figura 2.3 – Categorias taxonômicas básicas de classificação. ....	14
Figura 2.4 – Representação esquemática da circulação forçada pelo vento na camada superior do oceano, sobreposta à distribuição média de temperatura da superfície do mar. ....	15
Figura 2.5 – Partes de um neurônio. ....	16
Figura 2.6 – Modelo de um neurônio artificial. ....	17
Figura 4.1 – Leitura e apresentação dos dados na tela e seleção dos atributos de entrada. .	21
Figura 4.2 – Visualização da rede neural criada pela aplicação <i>web</i> . ....	22
Figura 4.3 – Estatísticas da rede neural criada e <i>download</i> dos resultados. ....	22

## LISTA DE GRÁFICOS

Gráfico 2.1 – Gráfico da função degrau .....	18
Gráfico 2.2 – Gráfico da função sigmoidal .....	18
Gráfico 2.3 – Gráfico da função linear .....	18

## **LISTA DE TABELAS**

Tabela 2.1 – Exemplo de uma tabela de amostras de foraminíferos.....	14
--	----



## LISTA DE ABREVIATURAS E SIGLAS

<i>IA</i>	Inteligência Artificial
<i>RNA</i>	Rede Neural Artificial
<i>Rprop</i>	Retropropagação Resiliente
<i>TLU</i>	<i>Threshold Logic Unit</i>
<i>UFMS</i>	Universidade Federal de Santa Maria

## LISTA DE SÍMBOLOS

$\text{CaCO}_3$	Carbonato de Cálcio
$O^{16}$	Isótopo de oxigênio com número de massa 16
$O^{18}$	Isótopo de oxigênio com número de massa 18
$\beta$	Letra grega <i>Beta</i> minúscula
$\theta$	Letra grega <i>Theta</i> minúscula
$\varphi$	Letra grega <i>Phi</i> minúscula

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO .....</b>	<b>10</b>
1.1	OBJETIVOS .....	11
1.1.1	Objetivos Específicos .....	11
<b>2</b>	<b>REVISÃO BIBLIOGRÁFICA .....</b>	<b>12</b>
2.1	FORAMINÍFEROS .....	12
2.1.1	Classificação .....	13
2.1.2	Coleta de Amostras .....	14
2.1.3	Predição de Paleotemperaturas .....	14
2.2	REDES NEURAIS ARTIFICIAIS (RNAS) .....	15
2.2.1	Neurônios Biológicos .....	16
2.2.2	Neurônios Artificiais .....	17
2.2.2.1	<i>Função de Ativação</i> .....	17
<b>3</b>	<b>METODOLOGIA .....</b>	<b>19</b>
3.1	MOTIVAÇÃO .....	19
3.2	SELEÇÃO DOS ATRIBUTOS DE ENTRADA .....	19
3.3	FERRAMENTAS UTILIZADAS .....	20
<b>4</b>	<b>RESULTADOS .....</b>	<b>21</b>
	<b>REFERÊNCIAS BIBLIOGRÁFICAS .....</b>	<b>23</b>

# 1 INTRODUÇÃO

Foraminíferos são excelentes indicadores paleoambientais (temperatura, salinidade, profundidade e turbidez, etc.), bioestratigráficos (idade da rochas sedimentares) e isotópicos (átomos de um mesmo elemento químico que diferem no número de nêutrons). Encontrados desde o período Cambriano, possuem alta taxa de evolução, são altamente sensíveis às mudanças que ocorrem no ambiente e se mantêm preservados nos sedimentos por milhões de anos. São predominantemente abundantes nas costas marítimas, encontrados principalmente em água salgada, mas também, raras vezes, em águas doces ou em águas mixohalinas (HAYWARD, B.W.; LE COZE, F.; GROSS, O., 2019).

(ZUCON et al., 2011) diz que, cerca de 4000 espécies são bentônicas e 40 espécies são planctônicas. Registros destes microfósseis nos estratos são datados desde 300 milhões de anos atrás. São amplamente estudados, pois, a carapaça traz consigo valiosas informações. É possível reconstruir ambientes do passado, reconhecer rochas petrolíferas, entender as mudanças nos ambientes (naturais ou causadas pela ação do homem), entre outras.

Uma informação muito útil que pode ser analisada através das carapaças coletadas é o paleoclima. Segundo resultados obtidos em (BJÖRN; NORDLUND, 1997), as RNAs são excelentes ferramentas para predição de paleotemperaturas com base em arquivos de amostras de foraminíferos. É uma técnica que vem crescendo e tornando-se muito confiável nestes cenários.

Trabalhar com Redes Neurais Artificiais parte da necessidade de fazer os computadores serem autônomos e portanto serem capazes de aprender – sozinhos – a partir de dados de entrada (treinamento), quais são as saídas mais próximas do que é real (aprendizagem). Conforme as afirmações de (HAYKIN, 2001) e (SILVA; SPATTI; FLAUZINO, 2010), o uso de Redes Neurais Artificiais oferece algumas propriedades úteis e capacidades (todas as definições são aprofundadas no capítulo 2):

*Adaptabilidade:* a RNA é capaz de se adaptar os pesos das entradas a diferentes exemplos, através da experiência, adequando-se aos padrões de arquivos de entrada distintos;

*Analogia Neurobiológica:* trata-se da inspiração que esta abordagem tem com a capacidade rápida, paralela e eficaz que o cérebro humano tem de aprender;

*Capacidade de Aprendizado:* a Rede pode ser treinada e a partir dessa experiência aprender o comportamento das variáveis de entrada e qual o resultado (saída) esperado;

*Facilidade de Prototipagem:* RNAs podem ser implementadas facilmente em *hardware* ou *software*, pois, seu treinamento baseia-se em ajustes de pesos e seus resultados são obtidos através de fórmulas matemáticas;

*Generalização e Uniformidade:* na aprendizagem não-supervisionada, a variável de resultado é desconhecida. Mesmo assim a Rede Neural pode ser treinada e encontrar resultados satisfatórios;

*Não-Linearidade:* uma RNA é capaz de fazer cálculos complexos até encontrar uma boa saída.

São inclusas camadas ocultas (*hidden layers*;) que possibilitam ajustar as curvas para dados que não são possíveis separar através de uma reta (não linearmente separáveis);

*Organização dos Dados*: a rede se organiza de modo que os agrupamentos são feitos através de padrões e particularidades encontrados nos dados;

*Tolerância a Falhas*: mesmo que algum neurônio ou alguma conexão entre eles falhe, a saída não será seriamente afetada. Isto ocorre porque existem inúmeras interconexões em uma rede.

## 1.1 OBJETIVOS

Esta monografia tem como objetivo ilustrar a eficiência das redes neurais na estimativa de paleotemperaturas. Para demonstrar esta afirmação, foi desenvolvida uma aplicação web capaz de analisar um arquivo de amostras de foraminíferos que retorna as predições e estatísticas da rede.

### 1.1.1 Objetivos Específicos

- Pesquisar e implementar de uma rede neural artificial utilizando o algoritmo de retropropagação resiliente (*Resilient Backpropagation*);
- Criar uma aplicação web completa e acessível ao usuário;
- Analisar e aplicar o algoritmo de retropropagação resiliente no arquivo de amostras de foraminíferos;
- Ajustar os pesos dos atributos de entrada para maior precisão da RNA;
- Treinar e testar a RNA, esta deve aprender e retornar com boa exatidão as paleotemperaturas;
- Exibir de gráficos e estatísticas referentes aos resultados.

## 2 REVISÃO BIBLIOGRÁFICA

Este capítulo conta com duas seções, ele traz revisões bibliográficas que são primordiais para entendimento dos temas desta monografia. Primeiramente, são descritos os foraminíferos, bem como sua classificação biológica e como eles são capazes de armazenar, dentre outras, informações paleoclimáticas. Na segunda seção são trazidas definições importantes acerca de Redes Neurais e como funciona o seu ciclo, desde a coleta dos dados de entrada até a saída com as predições.


### 2.1 FORAMINÍFEROS

Foraminíferos são protistas unicelulares marinhos existentes desde o período Cambriano (entre 542 milhões e 488 milhões de anos atrás). São muito utilizados em paleoceanografia devido sua alta capacidade evolutiva e por se manterem preservados nos sedimentos durante milhões de anos. A coleta e análise destes protistas possibilita a predição de paleotemperaturas, a reconstrução de ambientes paleoecológicos e a descoberta de poços de petróleo, dentre outras valiosas informações (PETRÓ, 2018). Foraminíferos são envolvidos por uma testa (carapaça), esta pode conter uma ou várias câmaras que são interligadas por uma ou várias aberturas (ver figuras 2.1 e 2.2). Conforme diz (LOEBLICH et al., 1992 apud PETRÓ, 2018) estas conexões entre as câmaras por aberturas formam o nome do grupo, pois, em latim *foramen* (orifício) e *ferre* (possuir).

O modo de vida destes protistas os classifica como bentônicos ou planctônicos. As formas bentônicas foram as primeiras a surgir na terra e habitam o fundo dos oceanos. Elas possuem hábito infaunal ou epifaunal, quer dizer que vivem dentro ou abaixo dos substratos, ou vivem presas sobre o substrato respectivamente. E as planctônicas vivem à deriva, em águas mais altas, movimentando-se verticalmente. (UNIVERSITY COLLEGE LONDON, 2002).


Eles habitam, em sua maioria, as águas salgadas, porém, são encontrados também nas águas doces ou então nos estuários. Podem viver tanto na superfície quanto nas profundezas dos mares, rios e oceanos. São capazes de se adaptar desde as águas mais frias até as mais quentes. Sua abundância e sua variabilidade os torna os microfósseis mais estudados do mundo. (HAYWARD, B.W.; LE COZE, F.; GROSS, O., 2019).

Figura 2.1 – Exemplos de foraminíferos planctônicos.



Fonte: (UNIVERSITY COLLEGE LONDON, 2002).

Figura 2.2 – Exemplos de foraminíferos bentônicos.



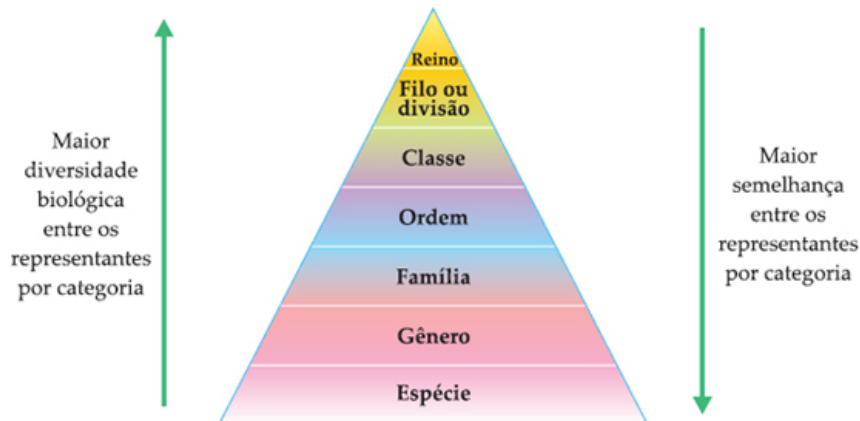
Fonte: (UNIVERSITY COLLEGE LONDON, 2002).

### 2.1.1 Classificação

Em 1753, Nilsson Linnæus, foi o precursor no que conhecemos como taxonomia moderna e propôs o Sistema Naturae (MANKTELOW, 2010) que agrupa os seres vivos conforme é ilustrado na figura 2.3.

Desde então, muitos autores tem divergências quanto a classificação exata dos foraminíferos, isso ocorre porque tais classificações sofrem bastantes mudanças devido ao descobrimento de novos seres e, portanto, novas especificações. Por isso, (RUGGIERO et al., 2015) propôs em 2015 a classificação mais atual que temos hoje, ele os define como organismos pertencentes ao reino *Chromista*, infrarreino *Rizharia*, filo *Retaria* e subfilo *Foraminifera*. Este subfilo conta com 3 classes: *Monothalamea* (com 4 ordens), *Globothalamea* (com 9 ordens) e *Tubothalamea* (com 2 ordens), totalizando 15 ordens.

Figura 2.3 – Categorias taxonômicas básicas de classificação.



Fonte: Blog do Desconversa.<sup>1</sup>

### 2.1.2 Coleta de Amostras

A coleta das amostras se dá pela extração dos sedimentos no fundo do oceano. Essa extração é feita em diversos pontos do local determinado, geralmente ocorre nas costas oceânicas, estes pontos onde eles são encontrados é chamado de testemunho. Ocorrem diversas etapas após a extração: o sedimento é lavado, peneirado, pesado, padronizado, enxugado, então é feita a triagem através de uma lupa estereoscópica e os microfósseis são colocados em lâminas. Por fim, os foraminíferos são identificados (FARIA, 2011; ARARIPE et al., 2016).<sup>1</sup>

Tabela 2.1 – Exemplo de uma tabela de amostras de foraminíferos.

Amostras	Pontos	Profundidade (m)	Local	Point_X	Point_Y
PL15	WPT 454	18,00	ITAMARACA	303546	9143163
PL16	WPT 458	25,00	ITAMARACA	308085	9141819
PL17	WPT 462	31,00	ITAMARACA	314280	9141660
PL18	WPT469	19,80	ITAMARACA	304856	9140444

Fonte: Adaptado de (ARARIPE et al., 2016).


### 2.1.3 Predição de Paleotemperaturas

Aproximadamente 70% do planeta é coberto por água que ficam em constante movimento. Este movimento (que pode ser causado por ventos, gravidade, variação da superfície) sempre varia e as águas se deslocam, isto explica as variações climáticas. O mar possui diferentes temperaturas, são mais altas nos trópicos e mais frias conforme chegam perto dos polos. Nas baixas latitudes as águas são mais leves e nas altas são mais pesadas (CAMPOS, 2014).

<sup>1</sup>Disponível em: <<https://descomplica.com.br/blog/biologia/resumo-taxonomia-saude/>> Acesso em abr. 2019.



Figura 2.4 – Representação esquemática da circulação forçada pelo vento na camada superior do oceano, sobreposta à distribuição média de temperatura da superfície do mar.



Fonte: (CAMPOS, 2014).

A testa dos foraminíferos utilizados na predição de paleotemperaturas é envolvida por um biomineral: a calcita (carbonato de cálcio  $[CaCO_3]$ ). Ela é capaz de armazenar informações sobre a proporção dos isótopos de oxigênio  $O^{16}$  (isótopo leve) e  $O^{18}$  (isótopo pesado). Quando ocorre o período glacial a geleira armazena o  $O^{16}$  e o oceano se enche de  $O^{18}$ . Em períodos interglaciais, ocorre o degelo e então a devolução destes isótopos ao mar, trazendo o equilíbrio novamente. (PETRÓ, 2013). É justamente essa proporção que define a estimativa da temperatura da época em que elas viveram.

## 2.2 REDES NEURAIS ARTIFICIAIS (RNAS)

Nos últimos anos as máquinas tem tido cada vez mais poder computacional, além disso, cada vez mais dados são produzidos e buscados. A Inteligência Artificial busca permitir que as máquinas pensem e ajam como humanos. A necessidade cada vez maior de armazenamento, comunicação e a complexidade dos problemas computacionais faz com que seja fundamental automatizar e dar autonomia às ferramentas computacionais (FACELI et al., 2011). Através de técnicas de Machine Learning (Aprendizagem de Máquina) computadores podem ser treinados e a partir da experiência definir qual é a melhor saída para quaisquer problemas apontados. A RNA é uma abordagem que está inclusa em Machine Learning e busca reproduzir as conexões e aprendizagens cerebrais.


O cérebro humano é uma estrutura complexa e com alta taxa de aprendizagem, através de estímulos entre neurônios ele é capaz de retornar rapidamente informações. Diversos neurônios são conectados entre si, essa combinação de neurônios é chamada de rede neural (TAFNER; XEREZ; FILHO, 1995). Redes Neurais Artificiais são baseadas nestas mesmas conexões, onde cada entrada (nó) simula um neurônio e as combinações entre as entradas revelam

a melhor saída. Parte de uma amostra de dados é selecionada para treino, então estes nós, que possuem diferentes pesos, se interligam com outros nós. Estas informações são calculadas e seus resultados entram em uma função de ativação. A função de ativação é responsável por ativar (1) ou não ativar (0) uma ligação. A outra parte é definida para teste, neste momento a RNA já assimilou o padrão dos dados de treino e é capaz de prever quais são as saídas para os dados de teste. (HAYKIN, 2001). As próximas subseções descrevem mais claramente estas afirmações.

### 2.2.1 Neurônios Biológicos

O ser humano é capaz de realizar inúmeras ações, como: andar, comer, falar e principalmente aprender. Isso ocorre pela grande capacidade de aprendizagem que o cérebro apresenta. O cérebro possui cerca de 100 bilhões de células nervosas, chamadas de neurônios, que são capazes de processar e transmitir informações paralelamente (KOVÁCS, 1997). Eles operam paralelamente, conduzindo impulsos nervosos, também chamados de estímulos elétricos ou potencial de ação. O neurônio é composto por três partes: dendritos, axônios e corpo celular, também conhecido como soma (KOVÁCS, 2006). Estas partes podem ser observadas na figura 2.4.<sup>2</sup>

Figura 2.5 – Partes de um neurônio.



Fonte: Página do site Só Biologia.<sup>2</sup>


Segundo (TAFNER; XEREZ; FILHO, 1995), a transmissão de um impulso nervoso ocorre quando o neurônio capta, através de reações físico-químicas, o estímulo dos dendritos e o transmite pelo axônio. Este estímulo é transformado em um impulso elétrico (potencial de ação), percorre o axônio e atinge um outro neurônio, esta conexão se chama sinapse. Um neurônio biológico é disparado quando ele atinge seu limiar de excitação (CARVALHO; BRAGA; LUDERMIR, 2012).

<sup>2</sup>Disponível em: <<https://www.sobiologia.com.br/conteudos/FisiologiaAnimal/nervoso2.php>> Acesso em abr. 2019.

### 2.2.2 Neurônios Artificiais

A base de funcionamento de um neurônio artificial são cálculos matemáticos. Conforme explicação de (CARVALHO; BRAGA; LUDERMIR, 2012), as  $n$  variáveis de entrada (dendritos) recebem valores  $x_1, x_2, x_3, x_n$ , a variável de saída (axônio) recebe um valor  $y$  e são aplicados pesos em cada interconexão (sinapses)  $w_1, w_2, w_3, w_n$ . O neurônio artificial irá passar por uma função de ativação com valor 0 (não disparar) ou 1 (disparar) quando a soma dos valores  $x_i w_i$  ultrapassarem seu limite ou *threshold* (limiar de ativação ou excitação) representado por  $\theta$ .

Figura 2.6 – Modelo de um neurônio artificial.



Fonte: Adaptado de (HAYKIN, 2001)

#### 2.2.2.1 Função de Ativação


Nesta subseção serão apresentadas as funções de ativação mais comumente utilizadas, baseadas nas variáveis da figura 2.6 e nas descrições de (SILVA; SPATTI; FLAUZINO, 2010). A função de ativação  $\varphi(u)$  define qual será a saída  $y$  da rede neural. As entradas  $x$  são multiplicadas pelos seus respectivos pesos  $w$  e os valores resultantes são somados  $\Sigma$ . Após a soma teremos um potencial de ativação  $u$  que é o resultado da diferença entre o valor do somador e o limiar de ativação. O domínio  $u$  é aplicado a função  $g$  que limita a saída  $y$  em intervalos aceitáveis para as imagens. Finalmente, temos a saída  $y$ , que é a relação da combinação de todas as entradas a rede, ela pode ser o valor final ou o valor que outros neurônios interligados podem utilizar.

##### a) Função degrau

Quando o potencial de ativação  $u$  for  $\geq 0$  o resultado da função será 1, ou seja, o neurônio será ativado. Do contrário, quando  $u$  for  $< 0$ , o neurônio não será ativado.

$$\varphi(u) = \begin{cases} 1 & \text{se } v \geq 0 \\ 0 & \text{se } v < 0 \end{cases} \quad (2.1)$$

Gráfico 2.1 – Gráfico da função degrau



Fonte: Adaptado de (SILVA; SPATTI; FLAUZINO, 2010)


a) Função sigmoidal (logística)

O resultados apresentados por esta função sempre estarão entre 0 e 1.

$$\varphi(u) = \frac{1}{1 + e^{-\beta \cdot u}} \quad (2.2)$$

onde  $\beta$  é uma constante real.

Gráfico 2.2 – Gráfico da função sigmoidal




Fonte: Adaptado de (SILVA; SPATTI; FLAUZINO, 2010)

d) Função linear

Os valores resultantes desta função são os mesmos valores de  $u$ .

$$\varphi(u) = u \quad (2.3)$$

Gráfico 2.3 – Gráfico da função linear



Fonte: Adaptado de (SILVA; SPATTI; FLAUZINO, 2010)

### 3 METODOLOGIA

Este capítulo tem a função de avaliar o quão bom e prático é o uso de Redes Neurais supervisionadas para a estimativa de paleotemperaturas. As próximas seções explicam todos os passos (escolha dos atributos de entrada, ferramentas utilizadas, análise e computação dos dados) utilizados para a criação do Preditor de Paleotemperaturas, além de uma descrição sobre a motivação e considerações sobre este estudo e o que ainda falta realizar.

#### 3.1 MOTIVAÇÃO

De acordo com (EEROLA, 2003) nosso planeta tem 4,5 bilhões de anos e durante todo esse tempo ocorreram diversas mudanças climáticas drásticas. De certa forma todas as variações que ocorreram possuem ligações. O clima congelante fica estável, depois desértico, após volta à estabilidade e tudo isso se repete.

Como diz o Painel Brasileiro de Mudanças Climáticas (2014):

Reconstituições paleoclimáticas assumem marcante relevância atualmente, em face à necessidade de se atribuir causas às alterações ocorridas no clima da Terra durante as últimas décadas e, também, a fim de auxiliar o estabelecimento de cenários climáticos futuros.

Como já mencionado na seção 2, foraminíferos são excelentes indicadores paleoclimáticos, outrossim, Redes Neurais Artificiais são excelentes ferramentas de predição. Consequentemente, aplicar RNAs em amostras de foraminíferos, traz resultados bem precisos, satisfatórios e importantes para a história do planeta.

#### 3.2 SELEÇÃO DOS ATRIBUTOS DE ENTRADA

Os atributos de entrada estão presentes em um arquivo *.csv* ou *.xlsx*. No *dataset* encontramos a densidade da população de cada espécie de foraminíferos encontradas em cada testemunho e a última coluna conta com a temperatura estimada.

Dentro do aplicativo *web*, o usuário pode selecionar um arquivo, após o *upload* ele define quais serão as variáveis de entrada e qual será a classe utilizada, que segundo Fritsch, Guenther e Guenther (2019, p. 7, tradução nossa), "é uma descrição simbólica sobre o modelo a ser predito"<sup>3</sup>.

---

<sup>3</sup>"a symbolic description of the model to be fitted"

### 3.3 FERRAMENTAS UTILIZADAS

A aplicação para predição de paleotemperaturas foi totalmente desenvolvida na linguagem R, utilizando principalmente os pacotes *shiny* e o *neuralnet*. O pacote *shiny* permite a criação de aplicações *web*, onde temos o lado da interface (*user side*) e o lado do servidor (*server side*).

É no *shiny server* que são feitos os códigos referentes a leitura do arquivo, seleção de atributos, criação da rede neural, computação dos dados e estatísticas. Primeiramente são separados 90% dos dados do *dataset* para treinamento da rede, os outros 10% são dados de teste. A biblioteca *neuralnet* recebe como parâmetro os atributos de entrada selecionados pelo cliente, os dados de treino, o número de camadas ocultas, o limite, o algoritmo que nesse caso é o de retropropagação resiliente (rprop+). A partir de agora a rede já aprendeu as configurações de entrada, é capaz computar os dados e predizer as temperaturas com base nos dados de teste.

Todos os dados do *dataset* e as predições são visíveis ao usuário através aplicação. Bem como dados estatísticos sobre a precisão e o número de erros da rede.

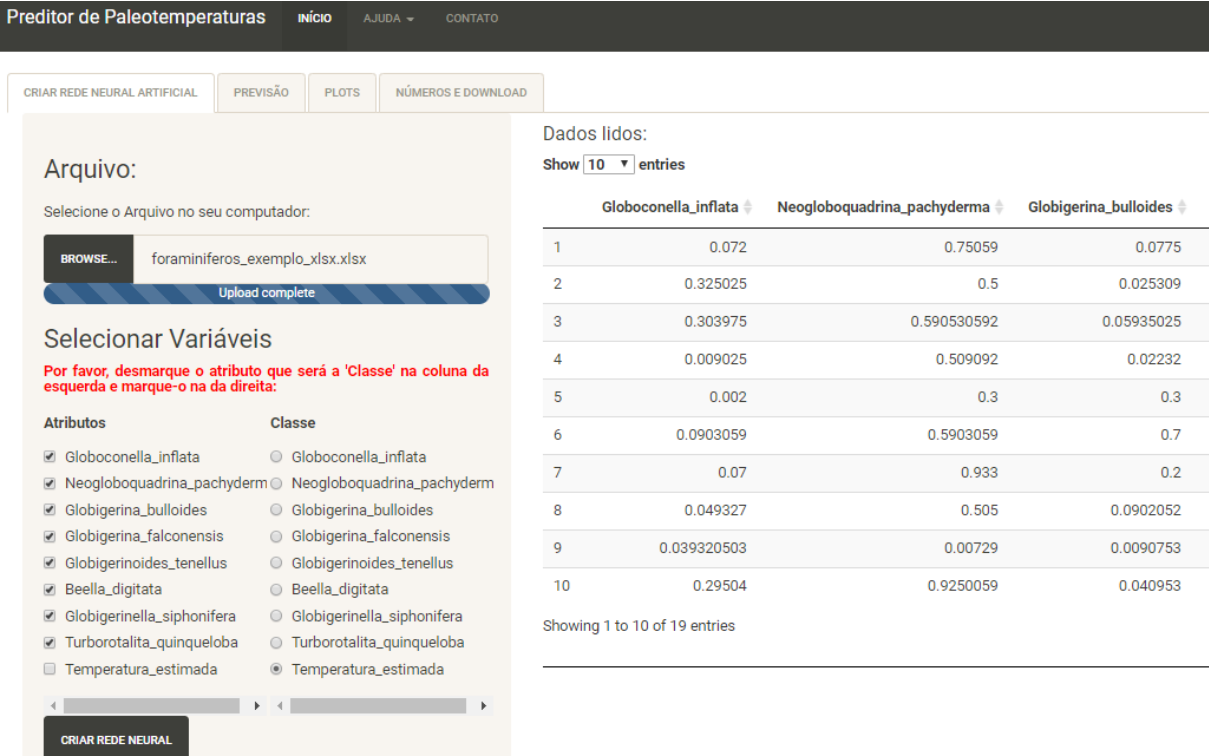
## 4 RESULTADOS

Até o presente momento, já existe uma aplicação funcional. É possível fazer o *upload* dos arquivos, visualizar o *dataset*, criar a rede neural, visualizar as previsões, visualizar graficamente a rede, fazer *download* do resultado, ver as estatísticas e o quão precisa ela é.

O que ainda precisa ser feito são ajustes e melhorias nos pesos das variáveis para resultar em previsões com acima de 90% de precisão. Também se faz necessário criar mais gráficos e estatísticas sobre a rede, bem como melhorar o *layout* da aplicação e definir o conteúdo da aba 'ajuda'.

Abaixo podem ser vistas algumas capturas de tela para uma melhor compreensão do que foi desenvolvido até agora:

Figura 4.1 – Leitura e apresentação dos dados na tela e seleção dos atributos de entrada.



Preditor de Paleotemperaturas INÍCIO AJUDA CONTATO

criar rede neural artificial PREVISÃO PLOTS NÚMEROS E DOWNLOAD

Arquivo:

Selecione o Arquivo no seu computador:

BROWSE... foraminiferos\_exemplo.xlsx

Upload complete

Selecionar Variáveis

Por favor, desmarque o atributo que será a 'Classe' na coluna da esquerda e marque-o na da direita:

Atributos	Classe
<input checked="" type="checkbox"/> Globoconella_inflata	<input type="radio"/> Globoconella_inflata
<input checked="" type="checkbox"/> Neogloboquadrina_pachyderma	<input type="radio"/> Neogloboquadrina_pachyderma
<input checked="" type="checkbox"/> Globigerina_bulloides	<input type="radio"/> Globigerina_bulloides
<input checked="" type="checkbox"/> Globigerina_falconensis	<input type="radio"/> Globigerina_falconensis
<input checked="" type="checkbox"/> Globigerinoides_tenellus	<input type="radio"/> Globigerinoides_tenellus
<input checked="" type="checkbox"/> Beella_digitata	<input type="radio"/> Beella_digitata
<input checked="" type="checkbox"/> Globigerinella_siphonifera	<input type="radio"/> Globigerinella_siphonifera
<input checked="" type="checkbox"/> Turborotalita_quinqueloba	<input type="radio"/> Turborotalita_quinqueloba
<input type="checkbox"/> Temperatura_estimada	<input checked="" type="radio"/> Temperatura_estimada

CRIAR REDE NEURAL

Dados lidos:

Show 10 entries

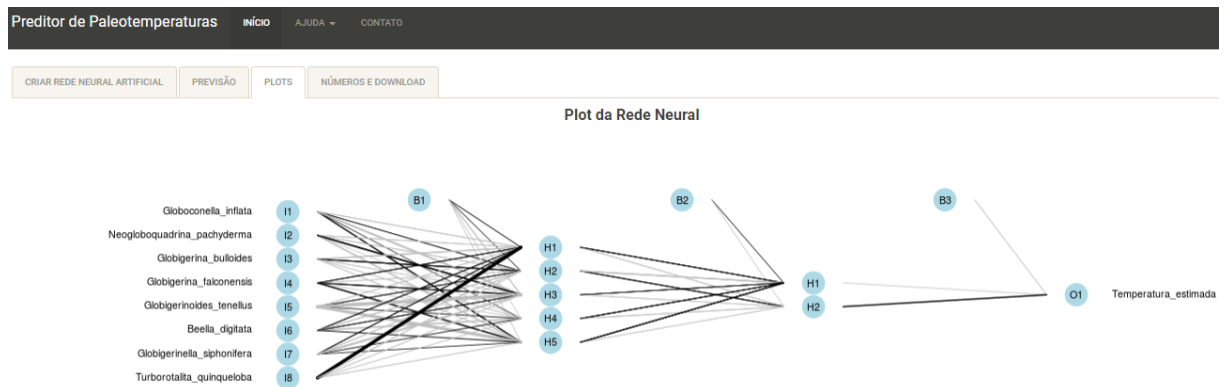
	Globoconella_inflata	Neogloboquadrina_pachyderma	Globigerina_bulloides
1	0.072	0.75059	0.0775
2	0.325025	0.5	0.025309
3	0.303975	0.590530592	0.05935025
4	0.009025	0.509092	0.02232
5	0.002	0.3	0.3
6	0.0903059	0.5903059	0.7
7	0.07	0.933	0.2
8	0.049327	0.505	0.0902052
9	0.039320503	0.00729	0.0090753
10	0.29504	0.9250059	0.040953

Showing 1 to 10 of 19 entries

Fonte: Captura de tela realizada pela autora no dia 15 de maio de 2019.

Primeiramente ocorre a seleção do arquivo, depois, a esquerda, o usuário seleciona quais são as variáveis de entrada e a classe. Por último clica em 'criar rede neural', a partir daí a aplicação realiza todas as ações citadas na subseção 2.2.2.

Figura 4.2 – Visualização da rede neural criada pela aplicação *web*.



Fonte: Captura de tela realizada pela autora no dia 15 de maio de 2019.

Nesta aba é possível visualizar graficamente a rede criada: a camada de entrada, as camadas ocultas, os limiares e a saída, respectivamente.

Figura 4.3 – Estatísticas da rede neural criada e *download* dos resultados.



Fonte: Captura de tela realizada pela autora no dia 15 de maio de 2019.

Finalmente, são apresentadas as estatísticas. Podemos ver o erro de treinamento, o erro de teste (erros relacionados a saída y da rede e a saída desejada), quantas passos foram necessários para chegar a estas saídas, bem como a precisão da rede neural artificial. Também é possível fazer o *download* de um arquivo *.csv* contendo os resultados da nossa rede neural artificial.



## REFERÊNCIAS BIBLIOGRÁFICAS

ARARIPE, R. V. C. d. et al. Caracterização da fauna de foraminíferos bentônicos da plataforma continental de Itamaracá, PE - Brasil. **Estudos Geológicos**, Laboratório de Paleontologia do Departamento de Geologia, Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, v. 26, n. 2, p. 91–107, 2016.

BJÖRN, A. M.; NORDLUND, U. Application of artificial neural networks to paleoceanographic data. **Palaeogeography, palaeoclimatology, palaeoecology**, Elsevier Science B. V., v. 136, n. 1-4, p. 359–373, 1997.

BRAGA, F. de V. A. **Estimativa dos parâmetros da resistência do solo ao cisalhamento através de pedotransferência**. 2014. 98 f. Tese (Doutorado em Engenharia Agrícola) — Universidade Federal de Santa Maria, Santa Maria, 2014.

CAMPOS, E. J. D. O papel do oceano nas mudanças climáticas globais. **Revista USP**, n. 103, p. 55–66, 2014.

CARVALHO, A. C. P. de L. F.; BRAGA, A. de P.; LUDERMIR, T. B. **Fundamentos de redes neurais artificiais**. Rio de Janeiro: Imprinta Gráfica e Editora, 1998. 246 p.

\_\_\_\_\_. **Redes neurais artificiais: teorias e aplicações**. 2. ed., 1ª reimpressão. ed. Rio de Janeiro: Livros Técnicos e Científicos Editora, 2012. 226 p.

CERENTINI, A. **Identificação do glaucoma em imagens do fundo olho utilizando aprendizagem profunda**. 2018. 84 f. Dissertação (Mestrado em Ciência da Computação) — Universidade Federal de Santa Maria, Santa Maria, 2018.

CUSHMAN, J. A. **Foraminifera: their classification and economic use**. 4. ed. Cambridge: Harvard University Printing Office, 1948. 605 p.

DIAZ, M. B. **Análise de diferentes métodos de preenchimento de falhas nos fluxos de CO<sub>2</sub>: estimativas sobre o arroz irrigado**. 2014. 85 f. Dissertação (Mestrado em Meteorologia) — Universidade Federal de Santa Maria, Santa Maria, 2014.

EEROLA, T. T. Mudanças climáticas globais: passado, presente e futuro. **Fórum de ecologia. Instituto de Ecologia Política, Universidade do Estado de Santa Catarina.**, 2003.

FACELI, K. et al. **Inteligência Artificial: uma abordagem de aprendizado de máquina**. Rio de Janeiro: Livros Técnicos e Científicos Editora, 2011. 378 p.

FARIA, G. R. de. **Biodiversidade de foraminíferos bentônicos e planctônicos da plataforma continental da região de Cabo Frio - RJ, Brasil**. 2011. 74 f. Monografia (Monografia) — Curso de Bacharelado em Ciências Biológicas, Universidade Federal Fluminense, Rio de Janeiro, 2011.

FERRAZ, R. C. **Sistema web e mobile para estimativa de evapotranspiração de referência utilizando redes neurais artificiais**. 2013. 119 f. Tese (Doutorado em Engenharia Agrícola) — Universidade Federal de Santa Maria, Santa Maria, 2013.

FRIDERICH, A. **Predição da performance de um reator UASB para tratamento de vinhaça usando identificação e redes neurais**. 2013. 97 f. Dissertação (Mestrado em Engenharia de Processos) — Universidade Federal de Santa Maria, Santa Maria, 2013.

FRITSCH, S.; GUENTHER, F.; GUENTHER, M. F. Package ‘neuralnet’. **Training of Neural Networks**, 2019.

GOULART, E. d. S. **Aplicação de redes neurais para a análise inversa de estruturas de concreto**. 1999. 70 f. Dissertação (Mestrado em Ciências em Engenharia Civil) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, 1999.

GURNEY, K. **An introduction to Neural Networks**. Sound Parkway: CRC Press, 1997. 232 p.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. Neural networks. In: \_\_\_\_\_. **The elements of Statistical Learning**. New York: Springer Science+Business Media, 2009. cap. 11, p. 389–416.

HAYKIN, S. S. **Redes Neurais: princípios e práticas**. 2. ed., 1ª reimpressão. ed. Porto Alegre: Artmed Editora, 2001. 900 p. Tradução de Paulo M. Engel.

HAYWARD, B.W.; LE COZE, F.; GROSS, O. **World Foraminifera Database**. World Register of Marine Species (WoRMS), 2019. Acesso em 30 abr. 2019. Disponível em: <<http://www.marinespecies.org/foraminifera/>>.

HESEMANN, M.; OTTWAY, B.; LEGOINHA, P. The foraminifera.eu project. a paleoinformatics bridge between science and community. **Comunicações Geológicas**, Laboratório Nacional de Energia e Geologia, v. 101, n. 1 (SI), p. 447–450, 2014.

INFANTE, A. G. de. **El Plancton de las aguas continentales**. Washington: Eva V. Chesneau, 1988. 130 p.

KOVÁCS, Z. L. **O cérebro e sua mente: uma introdução à Neurociência Computacional**. São Paulo: Livraria Triângulo Editora, 1997. 214 p.

\_\_\_\_\_. **Redes Neurais Artificiais fundamentos e aplicações: um texto básico**. 4. ed. São Paulo: Editora Livraria da Física, 2006. 174 p.

LOESCHE, C.; SARI, S. T. **Redes Neurais Artificiais: fundamentos e modelos**. Blumenau: Editora da FURB, 1996. 166 p.

MANKTELOW, M. History of taxonomy. **Lecture from Dept. of Systematic Biology, Uppsala University**, v. 29, 2010.

NUNES, F. C.; BOAS, G. d. S. V.; SILVA, E. F. da. Mudanças climáticas e seus reflexos na paisagem do quaternário: primeiras reflexões. **Embrapa Solos-Documents (INFOTEC-A-E)**, Rio de Janeiro: Embrapa Solos, 2012., 2012.

PADILHA, D. G. **Modelo de apoio à decisão aplicado ao planejamento territorial de silvicultura baseado em análise multicritério de redes neurais artificiais**. 2014. 98 f. Tese (Doutorado em Engenharia Florestal) — Universidade Federal de Santa Maria, Santa Maria, 2014.

Painel Brasileiro de Mudanças Climáticas. Informações paleoclimáticas brasileiras. In: \_\_\_\_\_. **Base Científica das Mudanças Climáticas**. Rio de Janeiro: PMBC, 2014. cap. 4, p. 130.

PEREIRA, A. G. **Aplicação de evolução estrutural e paramétrica de redes neurais dinâmicas na melhoria de desempenho de métodos de assimilação de dados**. 2011. 58 f. Monografia (Trabalho de Conclusão de Curso) — Curso de Graduação em Ciência da Computação, Universidade Federal de Santa Maria, Santa Maria, 2011.

PEREIRA, T. dos S. **Uso de Inteligência Artificial para estimativa da capacidade de suporte de carga do solo**. 2017. 179 f. Tese (Doutorado em Engenharia Agrícola) — Universidade Federal de Santa Maria, Santa Maria, 2017.

PETRÓ, S. M. **Guia para classificação de foraminíferos planctônicos recentes**. Porto Alegre: IGEO/UFRGS, 2009. 218 p.

PETRÓ, S. M. **Evolução paleoceanográfica e estratigrafia isotópica com foraminíferos planctônicos no quaternário tardio da Bacia de Campos**. 2013. 60 f. Dissertação (Mestrado em Geociências) — Universidade Federal do Rio Grande do Sul, Porto Alegre, 2013.

\_\_\_\_\_. **Introdução ao estudo dos foraminíferos**. Porto Alegre: IGEO/UFRGS, 2018. 218 p.

PETRÓ, S. M.; PIVEL M. A. G.; COIMBRA, J. C. **Foraminíferos planctônicos do Quaternário do Atlântico Sul: elaboração de um banco de dados fotográfico, taxonômico, bioestratigráfico e ecológico**. Porto Alegre: Laboratório de Microfósseis Calcários, 2018. Acesso em 09 abr. 2019. Disponível em: <<https://www.ufrgs.br/microfosseis/microfosseis/foraminiferos/>>.

RUGGIERO, M. A. et al. Correction: A higher level classification of all living organisms. **Plos one**, Public Library of Science, v. 10, n. 6, p. e0130114, 2015.

SAAD, C. s. Aplicação de um modelo de redes neurais à programação da produção. **Boletim Técnico da Escola Politécnica da USP, Departamento de Engenharia da Produção, BT/048**, v. 3, n. 5, p. 1–24, 1998.

SILVA, I. N. da; SPATTI, D. H.; FLAUZINO, R. A. **Redes Neurais Artificiais: para engenharia e ciências aplicadas**. São Paulo: Artliber Editora, 2010. 399 p.

SODRÉ, ULYSSES. **Matemática Essencial: Superior: Cálculo: Máximos e mínimos: Teste da primeira derivada**. Londrina: Universidade Estadual de Londrina – Departamento de Matemática, 2006. Acesso em 13 mai. 2019. Disponível em: <<http://www.uel.br/projetos/matessencial/superior/calculo/maxmin/mm02.htm>>.

TAFNER, M. A.; XEREZ, M. de; FILHO, I. W. R. **Redes Neurais Artificiais: introdução e princípios de neurocomputação**. Blumenau: Editora FURB e Editora Eko, 1995. 199 p.

UNIVERSIDADE DE SÃO PAULO. **Continuidade**. São Paulo: Instituto de Matemática e Estatística, 2000. Acesso em 13 mai. 2019. Disponível em: <<http://ecalculo.if.usp.br/derivadas/popups/continuidade.htm>>.

UNIVERSITY COLLEGE LONDON. **Foraminifera**. Gower Street: Postgraduate Unit of Micropalaeontology, Department of Earth Sciences, 2002. Acesso em 25 abr. 2019. Disponível em: <<https://www.ucl.ac.uk/GeolSci/micropal/foram.html>>.

ZUCON, M. H. et al. Microfósseis. In: \_\_\_\_\_. **Paleontologia Geral**. São Cristovão: Universidade Federal de Sergipe / CESAD, 2011. p. 55–67.

ZUUR, A. F.; IENO, E. N.; MEESTERS, E. H. W. G. **A beginner's guide to R**. New York: Springer Science+Business Media, 2009. 218 p.